

1. ACQUISITION PIPELINE :

Source	Packages	Data category	Data type
GDC database	"TCGAbiolinks", "SummarizedExperiment"	"Transcriptome Profiling"	"Gene Expression Quantification"

data/raw/	Description	Size	Shape
"counts_samples_x_genes.csv.gz"	counts by "sample_barcode"	28.775 kb	553 samples x 60660 genes
"metadata_clinical_merged.csv.gz"	clinical metadata by "patient_barcode"	176 kb	553 patients x 175 columns
"gene_annotation.csv.gz"	Annotated genes by "ensembl_gene_id", "gene_symbol", "gene_type"	501 kb	60660 genes x 2 columns


barcode	ENSG00000000003.15	ENSG00000000005.6	ENSG00000000419.13	ENSG0000028861.1	ENSG0000028862.1
TCGA-EY-A1GK-01A-11R-A13S-07	1904	2	607	0	1
TCGA-FI-A2CX-01A-11R-A17B-07	496	1	839	0	1

barcode	patient	sample	shortLetterCode	...	treatments_radiation_residual_disease	bcr_patient_barcode.y
TCGA-EY-A1GK-01A-11R-A13S-07	TCGA-EY-A1GK	TCGA-EY-A1GK-01A	TP	...	NaN	TCGA-EY-A1GK
TCGA-FI-A2CX-01A-11R-A17B-07	TCGA-FI-A2CX	TCGA-FI-A2CX-01A	TP	...	NaN	TCGA-FI-A2CX

ensembl_gene_id	gene_symbol	gene_type
ENSG00000000003.15	TSPAN6	protein_coding
ENSG00000000005.6	TNMD	protein_coding
ENSG00000000419.13	DPM1	protein_coding


2. QC NORMALIZATION PIPELINE :

Distribution des valeurs d'expression (reads RNA-seq en valeurs absolues)



RAW Shape : 60660 genes x 553 samples.
 MAPPING & FUSION Shape : 59427 genes x 553 samples.
 Post-QC Filtering Shape : 21168 genes x 553 samples.


Distribution des valeurs d'expression (densité de reads RNA-seq)



Objectif biologique : corriger biais technique pour une meilleure comparabilité biologique

- Normalise par profondeur de séquençage (counts par million)
- Échelle logarithmique (évite domination gènes ultra-exprimés)

Structure globale (coloré par Tumor Grade)



" expr_norm_filtered.csv.gz "	counts post-qc, filtering and log2-normalization	58.886 kb	553 samples x 21168 genes
---	--	-----------	---------------------------

3. PRE-PROCESSING PIPELINE (auto-encodeur unsupervised) :

3.1. Features selection :

3.1.1. Benchmark (512, 1024, 2048, 4096)


- Sélection top N gènes par variance
- Split 80/20 (442 train / 111 validation)
- Entraînement mini-AE (10 epochs)
- Calcul Train MSE et Val MSE
- Comparaison MSE (Mean Squared Error) reconstruction

Val MSE = Erreur de reconstruction sur l'ensemble de validation

$$MSE = \frac{1}{n \times p} \sum_{i=1}^n \sum_{j=1}^p (x_{ij} - \hat{x}_{ij})^2$$


Où :

- x_{ij} = expression réelle du gène j chez patient i
- $\hat{x}_{ij}$ = reconstruction par l'autoencodeur
- n = nombre de patients (validation set)
- p = nombre de gènes (512, 1024, 2048 ou 4096)



Conclusion : 4096 gènes = optimal (meilleure reconstruction + convergence stable)

3.1.2. Filtrage par haute variance (TOP 4096)



3.2. Standardisation Z-score:

Transformation mathématique :

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

Pour chaque gène j :


- μ_j = moyenne d'expression du gène sur tous les patients
- σ_j = écart-type du gène
- z_{ij} = valeur standardisée pour patient i

Objectif mathématique : uniformisation pour convergence ML

- Convergence gradient descent : tous gènes sur même échelle
- Évite domination : gènes fortement exprimés "n'écrasent" pas les autres
- Activation functions : ReLU/sigmoid fonctionnent mieux dans $[-3, 3]$

Résultat : Chaque gène a *moyenne* = 0 et *écart-type* = 1


Impact du preprocessing sur la distribution des valeurs d'expression



La transformation des 11,7M valeurs initiales (graphique 1) vers les 2,3M valeurs finales (graphiques 2-3) illustre la concentration progressive de l'information biologique : la sélection des 4096 gènes à plus haute variance élimine préférentiellement le pic des faibles expressions (variance = bruit technique), tandis que le Z-score compresse la distribution log-normale asymétrique en une gaussienne parfaitement centrée ($\mu=0.000, \sigma=1.000$). Cette standardisation garantit que chaque gène contribue équitablement au calcul de la loss MSE de l'autoencodeur, indépendamment de son niveau d'expression absolu.




3.3. Post-validation



Heatmap de co-expression (Top 30 gènes haute variance) : validation visuelle de la structure biologique après preprocessing. Le clustering hiérarchique révèle des modules de gènes co-exprimés, confirmant que les données contiennent un signal organisé avant l'entraînement de l'autoencodeur.

Triptyque de Réduction Dimensionnelle - Baseline Pré-Compression
(n=553, 4096 gènes)



3 méthodes de projection des 4096 gènes en 2D :

- PCA : linéaire
- UMAP : non-linéaire (préserve structure locale)
- t-SNE : non-linéaire (maximise séparation)

Coloration par histologie : Endometrioid (bleu), Serous (orange), Mixed (vert)

Baseline pré-compression : le triptyque révèle un signal biologique non-linéaire (UMAP/t-SNE > PCA).

L'autoencodeur devra préserver cette séparation histologique dans son espace latent compressé.

"X_for_autoencoder.csv.gz"	, features selection+ Z-score	20,025 kb	553 samples x 4096 genes
--	---	-----------	--------------------------

4. Entraînement Autoencodeur (AE Non-Supervisé):

4.1. Objectif :

Compression non-linéaire de l'espace génomique (4096 gènes → espace latent Z compact) pour extraction de représentations biologiques pertinentes.

4.2. Stratégie :


- Bottleneck compact (32 dim) : Forcer la découverte de signatures biologiques stables (compression forte pour filtrer le bruit transcriptomique)
- Full cohorte (553 patients) : Maximiser la richesse biologique pour l'apprentissage non-supervisé
- Validation kNN (k=10) : Démontrer que l'espace latent préserve ou améliore la capacité prédictive

4.3. Test bottleneck empirique (32 vs 64 dimensions) :

4.3.1. Split 90/10 pour test :

Compromis entre richesse données (90% train) et monitoring overfitting (10% val)

4.3.2. Entraînement rapide 20 epochs



Conclusion : Performances identiques. compression maximale sans perte de qualité. Pas de gain à doubler la dimensionnalité.

4.4. Entraînement autoencodeur

4.4.1. Architecture réseaux de neurones :

Architecture symétrique à 8 couches Dense :

4096 → 2048 → 1024 → 512 → LATENT_DIM (32) → 512 → 1024 → 2048 → 4096

- **Encoder** : 4 couches (compression progressive par facteur 2)
- **Bottleneck** : 32 dimensions (compression 128×)
- **Decoder** : 4 couches (reconstruction symétrique)
- **Activations** : ReLU (couches intermédiaires), linéaire (sortie)
- **Paramètres** : 22,1M (99,93% entraînaibles)

4.4.2. Split final 90/10

Configuration du Dataset :

- Entraînement : 497 profils (90%)
- Validation : 56 profils (10%)
- Dimension : 4096 gènes

4.4.3. Construction architecture

Régularisation intégrée à l'architecture :

- **L2 ($\lambda=0.001$)** : Pénalise les poids élevés en ajoutant $0.001 \times \sum(w^2)$ à la loss MSE. Force le réseau à distribuer l'information sur plusieurs neurones plutôt que sur-pondérer certaines connexions, réduisant ainsi l'overfitting sur cette architecture profonde (9 couches, 22M paramètres).
- **Dropout (0.2-0.3)** : Désactive aléatoirement 20-30% des neurones à chaque batch d'entraînement. Oblige le réseau à apprendre des représentations redondantes et robustes, car aucun neurone ne peut compter sur la présence systématique de ses voisins.
- **BatchNormalization** : Normalise les activations entre couches ($\mu=0, \sigma=1$) à chaque batch. Stabilise la convergence en évitant l'explosion/disparition des gradients dans cette architecture profonde, et accélère l'entraînement en permettant un learning rate plus élevé.

4.4.4. Configuration Callbacks

Surveillance dynamique pendant l'entraînement :

- **EarlyStopping (patience=15)** : Surveille la val_loss à chaque epoch. Si aucune amélioration pendant 15 epochs consécutifs, arrête l'entraînement automatiquement. Évite de gaspiller du temps de calcul et prévient l'overfitting tardif.
- **ReduceLROnPlateau (patience=7, factor=0.5, min_lr=1e-6)** : Surveille la val_loss. Si stagnation pendant 7 epochs, réduit le learning rate de moitié ($LR \times 0.5$). Permet d'affiner la recherche du minimum global en réduisant progressivement la taille des "pas" d'optimisation jusqu'à un minimum de 10^{-6} .
- **ModelCheckpoint** : Sauvegarde automatiquement le modèle à chaque fois qu'une nouvelle meilleure val_loss est atteinte. Garantit la récupération du meilleur état du réseau même si l'entraînement dégrade les performances en fin de parcours (overfitting).

→ **Complémentarité** : Ces mécanismes agissent en synergie : la régularisation contraint la structure interne du réseau, tandis que les callbacks pilotent dynamiquement le processus d'optimisation pour maximiser la généralisation.


4.4.5. Entraînement

L'autoencodeur a été construit avec une architecture symétrique profonde de 8 couches Dense permettant une compression progressive par paliers de 2 (4096 → 2048 → 1024 → 512 → 32 → 512 → 1024 → 2048 → 4096). Le modèle compte 22,1 millions de paramètres, dont 99,93% sont entraînaables. La régularisation combine L2 ($\lambda=0.001$), Dropout adaptatif (0.2-0.3), et BatchNormalization pour stabiliser la convergence. Les couches intermédiaires utilisent l'activation ReLU, tandis que la couche de sortie utilise une activation linéaire pour préserver les valeurs négatives des données normalisées Z-score ($\mu=0, \sigma=1$).

"autoencoder_latent32.keras"	Architecture	43 kb	9
------------------------------	--------------	-------	---

Comparatifs avec études littératures

Étude	Année	Type	Gènes (input)	Bottleneck	Paramètres	Application
Way & Greene	2018	VAE	5,000	100	~20M	Pan-cancer TCGA
Dincer et al.	2018	DAE	10,000	512	~50M	Drug response
Chen et al.	2020	VAE	20,000	128	~80M	Single-cell RNA-seq
Rampášek et al.	2019	AE	8,000	256	~35M	Gene expression
Notre modèle	**2025**	**AE**	**4,096**	**32**	**~22M**	**TCGA-UCEC**



Interprétation

1. MSE (Époques 0 à 20)

On observe une descente ultra-rapide de la MSE (de ~8.0 à 1.0) : écart entre les gènes originaux des patientes et les gènes reconstruits par le modèle après être passés par le bottleneck.

C'est l'effet "découverte" : le modèle comprend très vite la structure globale des 4096 gènes. Cette phase initiale montre que le réseau identifie efficacement les motifs biologiques dominants communs à toutes les patientes dès les premières minutes de calcul.

2. MAE (L'écart Train/Val)

- Train MAE : continue de descendre proprement jusqu'à 0.46.
- Val MAE : commence à "flotter" et stagne autour de 0.60 à partir de l'époque 80.

L'écart qui se creuse à la fin montre que le modèle commence à mémoriser des détails spécifiques aux patientes du groupe d'entraînement qu'il ne retrouve pas chez les autres. Cet écart est accentué par la taille réduite du groupe de validation (10%), ce qui limite sa représentativité et favorise une mémorisation plus fine des spécificités du groupe d'entraînement (90%).

3. Pourquoi le EarlyStopping ne s'est pas déclenché ?

Comme la Val Loss a continué à s'améliorer jusqu'à la fin (passant de 0.79 à 0.75 entre l'époque 90 et 100 – cf. logs d'entraînement), le modèle a considéré qu'il progressait encore. Les graphiques montrent qu'on était vraiment à la limite avant l'overfitting.

4. Conclusion :

L'entraînement a été mené jusqu'à 100 époques. Bien que la perte d'entraînement continue de diminuer, la stagnation de la MAE de validation suggère qu'un entraînement prolongé n'apporterait pas de gain supplémentaire.

4.5. Extraction features latentes (Z)

4.5.1. Extraction avec encoder

Extraction = récupérer le milieu (bottleneck)

Avant extraction : AE entraîné peut reconstruire les données

Extraction : Pour chaque patient, on **arrête au bottleneck** (on n'utilise plus le decoder)

Les 32 dimensions capturent l'essence des 4096 gènes (compression intelligente, pas juste PCA)

Usage de Z :

- kNN : prédire OS 5 ans avec ces 32 features
- Visualisation : UMAP de Z
- Clustering : grouper patients par profil latent

C'est le "produit final" de l'AE.

4.5.2. Export features latentes (enregistrement)

Signatures (CSV) : « Z_latent_32dim.csv »

Encodeur (Keras) : « encoder_latent32.keras »

4.6. Évaluation qualité de compression

4.6.1. QUALITÉ RECONSTRUCTION :

MSE par patient


- Moyenne: 0.390991 | Médiane: 0.364104
- Outliers : 30 (5.4%)

4.6.2. SCATTER PLOTS RECONSTRUCTION

Analyse sur : TP53AIP1, EXOC3L4, NRP1, AC090004.2

Le choix des gènes pivots (PTEN, TP53, PIK3CA, KRAS) s'appuie sur la classification moléculaire établie par le consortium TCGA, qui démontre que ces altérations génomiques définissent les quatre sous-groupes pronostiques majeurs de l'UCEC [1].


[1] Cancer Genome Atlas Research Network, Kandoth, C., Schultz, N., et al. (2013). Integrated genomic characterization of endometrial carcinoma. *Nature*, 497(7447), 67–73



****Interprétation****

La forte corrélation visuelle avec la diagonale confirme que l'espace latent à 32 dimensions est une représentation biologique fidèle. Le modèle a réussi à condenser l'information tout en restant capable de reconstruire des gènes pivots de la pathologie UCEC avec une grande précision.

4.7. Distribution erreurs




****Interprétation****

L'erreur est centrée, faible et stable pour la majorité de la cohorte. La présence de quelques outliers est normale en cancérologie et ne remet pas en cause la structure de l'espace latent.

4.8. Comparaison UMAP avant/après

Comparaison Structure Avant/Après Compression (Échelles Unifiées)



****Interprétation****

- La comparaison visuelle des projections UMAP entre l'espace initial à 4096 gènes et l'espace latent à 32 dimensions démontre que l'autoencodeur préserve fidèlement l'intégrité du signal biologique : les groupes histologiques conservant une forme et une séparation quasi identiques.
- La translation horizontale et la rotation spatiale observées ne sont que des artefacts inhérents à la nature stochastique de l'algorithme UMAP, qui réorganise arbitrairement les coordonnées sans altérer les relations de distance entre les patientes.
- En résumé, cette stabilité topologique prouve que l'espace latent n'est pas une déformation de la réalité, mais une condensation exacte de l'information oncologique originale.

4.9. : Plus proches voisins

4.9.1. kNN (k=10) brut vs latent


****Hypothèse critique****

- Espace brut (4096 gènes) : Proximité peut être due au bruit technique
- Espace latent Z (32 dim) : Proximité = programmes biologiques majeurs similaires

****Test**** : Prédiction récurrence avec k=10 voisins

****Justification k=10**** :

Le choix de $k=10$ a été retenu pour équilibrer la robustesse statistique (limitation du bruit individuel) et la spécificité biologique (respect des sous-groupes moléculaires du TCGA dont les effectifs peuvent être limités).



****Interprétation des performances kNN (k=10)****

Les résultats de la classification par les k plus proches voisins ($k=10$) mettent en évidence deux conclusions majeures :

- Conservation de l'information prédictive : L'espace latent, bien qu'il ne comporte que 32 dimensions, obtient une AUC de 0,5365, ce qui est très proche de l' AUC de 0,5518 obtenue avec les 4096 gènes de l'espace brut. Cette stabilité démontre que l'autoencodeur a réussi à compresser l'information d'un facteur 128 sans perte significative du signal prédictif initial.
- Analyse de la performance absolue : Les valeurs d' AUC (proches de 0,5) indiquent une performance de prédiction de la récurrence à peine supérieure au hasard. Cela suggère que la tâche de prédire la récurrence clinique uniquement à partir du transcriptome est complexe, ou que le modèle kNN n'est pas l'estimateur le plus adapté pour capturer les nuances de cette variable.

****Conclusion : **** Le test de prédiction sur la récurrence (AUC = 0,53) démontre que bien que l'information soit compressée sans perte, cette variable spécifique (paper_recurrence_status) présente un signal transcriptomique trop faible pour être exploitable. Cela justifie l'utilisation de la variable OS 5-years plutôt que la récurrence comme cible (target) du MLP supervisé. En effet, la survie globale à 5 ans est plus susceptible de refléter les programmes biologiques majeurs identifiés dans l'espace latent, tout en étant une mesure plus objective car elle ne dépend pas de la fréquence des examens cliniques de suivi.

4.9.2. Validation biologique : Pureté des 10 voisins


Test de concordance

****Question**** : Les 10 voisins partagent-ils le même type histologique ?

****Pureté**** = % voisins du même type

****Pureté >80%**** = preuve cohérence biologique

Si les 10 voisins d'une patiente 'Séreuse' sont tous 'Séreux', l'AE a capturé l'essence de l'hétérogénéité tumorale.



****Interprétation**** de la cohérence biologique locale (Pureté k=10)

L'analyse de la pureté histologique de l'espace latent à 32 dimensions valide la qualité de la réduction de dimension à travers deux observations :

- Haute fidélité biologique : La pureté moyenne de 87,3 % démontre que l'autoencodeur regroupe spontanément les patientes selon leur pathologie réelle. Le fait que 83,1 % des patientes possèdent au moins 8 voisins sur 10 du même type histologique prouve que la proximité mathématique dans l'espace latent traduit une identité biologique profonde.
- Organisation structurale : La médiane à 100 % indique que la majorité des profils (notamment les types Endometrioid) forment des clusters extrêmement homogènes. Les scores de pureté plus faibles correspondent aux zones de transition ou aux types Mixed, où l'hétérogénéité tumorale rend la classification locale naturellement plus complexe.

****Conclusion :**** Ces résultats confirment que l'espace latent n'est pas une simple compression de données, mais un espace "débruité" où les programmes biologiques majeurs sont préservés. Cette solide structuration histologique valide l'utilisation des 32 signatures latentes pour la suite de l'étude : l'identification de biomarqueurs liés à la survie globale (OS 5-years).